

多媒体信息处理作业

姓名：张宗得

专业：人工智能

学号：2023K8009991013

目录

1 实验背景与任务	2
1.1 CIFAR-10 数据集	2
1.2 ResNet 网络架构	2
1.3 实验配置	4
2 激活函数的对比与分析	5
2.1 数学原理	5
2.1.1 Sigmoid	5
2.1.2 ReLU	5
2.1.3 LeakyReLU	5
2.1.4 GELU	5
2.2 实验结果对比	6
3 优化策略的对比与分析	7
3.1 数学原理	7
3.1.1 SGD (随机梯度下降)	7
3.1.2 SGD with Momentum	7
3.1.3 Adam (Adaptive Moment Estimation)	8
3.2 实验结果对比	8
4 模块设计创新: Ghost Module	9
4.1 改进动机	9
4.2 改进原理	10
4.3 代码实现	11
4.4 改进后的网络	12
4.5 性能评估	12
5 实验总结	14

1 实验背景与任务

1.1 CIFAR-10 数据集

CIFAR-10 是计算机视觉领域经典的图像分类数据集，包含 10 个类别，共 60000 张 32×32 彩色图像。其中训练集 50000 张，测试集 10000 张。

1.2 ResNet 网络架构

ResNet 通过引入“残差学习”解决了深层网络中的梯度消失和退化问题。本实验采用 ResNet-18 作为基础架构。

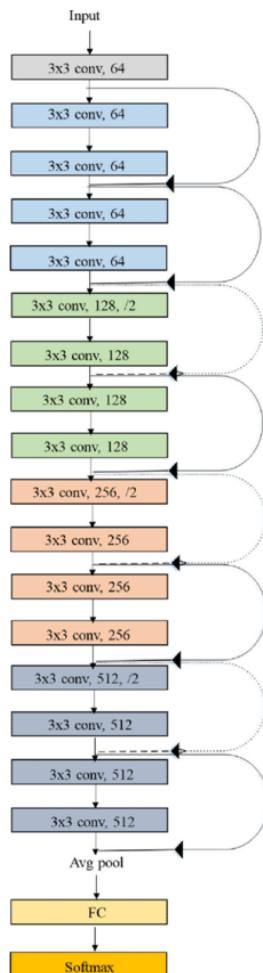


图 1: ResNet-18 结构示意图

```
1 class BasicBlock(nn.Module):
2     expansion = 1
3
4     def __init__(self, in_planes, planes, stride=1, activation_class=nn.ReLU):
5         super(BasicBlock, self).__init__()
```

```

6         self.conv1 = nn.Conv2d(in_planes, planes, kernel_size=3, stride=stride,
7             ↪ padding=1, bias=False)
8         self.bn1 = nn.BatchNorm2d(planes)
9         self.act1 = activation_class()
10
11        self.conv2 = nn.Conv2d(planes, planes, kernel_size=3, stride=1, padding
12            ↪ =1, bias=False)
13        self.bn2 = nn.BatchNorm2d(planes)
14        self.act2 = activation_class()
15
16        self.shortcut = nn.Sequential()
17        if stride != 1 or in_planes != self.expansion * planes:
18            self.shortcut = nn.Sequential(
19                nn.Conv2d(in_planes, self.expansion * planes, kernel_size=1,
20                    ↪ stride=stride, bias=False),
21                nn.BatchNorm2d(self.expansion * planes)
22            )
23
24    def forward(self, x):
25        out = self.act1(self.bn1(self.conv1(x)))
26        out = self.bn2(self.conv2(out))
27        out += self.shortcut(x)
28        out = self.act2(out)
29        return out
30
31
32 class ResNet(nn.Module):
33     def __init__(self, block, num_blocks, num_classes=10, activation_class=nn.
34             ↪ ReLU):
35         super(ResNet, self).__init__()
36         self.in_planes = 64
37         self.activation_class = activation_class
38         self.conv1 = nn.Conv2d(3, 64, kernel_size=3, stride=1, padding=1, bias=
39             ↪ False)
40         self.bn1 = nn.BatchNorm2d(64)
41         self.act1 = activation_class()
42
43         self.layer1 = self._make_layer(block, 64, num_blocks[0], stride=1)
44         self.layer2 = self._make_layer(block, 128, num_blocks[1], stride=2)
45         self.layer3 = self._make_layer(block, 256, num_blocks[2], stride=2)
46         self.layer4 = self._make_layer(block, 512, num_blocks[3], stride=2)

```

```

41
42     self.avgpool = nn.AdaptiveAvgPool2d((1, 1))
43     self.linear = nn.Linear(512 * block.expansion, num_classes)
44
45     def _make_layer(self, block, planes, num_blocks, stride):
46         strides = [stride] + [1]*(num_blocks-1)
47         layers = []
48         for stride in strides:
49             layers.append(block(self.in_planes, planes, stride, self.
50             ↪ activation_class))
51             self.in_planes = planes * block.expansion
52
53     return nn.Sequential(*layers)
54
55
56     def forward(self, x):
57         out = self.act1(self.bn1(self.conv1(x)))
58         out = self.layer1(out)
59         out = self.layer2(out)
60         out = self.layer3(out)
61         out = self.layer4(out)
62         out = self.avgpool(out)
63         out = out.view(out.size(0), -1)
64         out = self.linear(out)
65
66     return out
67
68
69     def ResNet18(activation_class):
70         return ResNet(BasicBlock, [2, 2, 2, 2], activation_class=activation_class)

```

Listing 1: ResNet 核心代码

1.3 实验配置

本实验基于 PyTorch 框架实现，使用云端 Nividia 4090 GPU + 4颗cpu核心进行训练。主要超参数设置如下：

- 批大小 (Batch Size): 128
- 训练轮数 (Epochs): 40
- 学习率 (Learning Rate): 0.01
- 优化器 (Optimizer): SGD / Adam / SGD with Momentum
- 激活函数 (Activation Function): ReLU / LeakyReLU / Sigmoid / GELU

2 激活函数的对比与分析

激活函数为神经网络引入了非线性因素。本实验在保持 ResNet-18 结构和优化策略以及超参数不变的情况下，对比了四种激活函数的性能表现。

2.1 数学原理

2.1.1 Sigmoid

Sigmoid 函数将输入映射到 $(0, 1)$ 区间：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (1)$$

缺点分析：在 x 绝对值较大时，导数趋近于 0，容易导致梯度消失；且输出不是以 0 为中心的。

2.1.2 ReLU

ReLU 是目前最常用的激活函数，公式如下：

$$\text{ReLU}(x) = \max(0, x) \quad (2)$$

优点：计算简单，在正区间解决了梯度消失问题，收敛速度快。

2.1.3 LeakyReLU

为了解决 ReLU 在 $x < 0$ 时神经元“死亡”的问题，LeakyReLU 引入了一个小的负斜率（实验中默认 slope=0.01）：

$$\text{LeakyReLU}(x) = \begin{cases} x & \text{if } x > 0 \\ \alpha x & \text{if } x \leq 0 \end{cases} \quad (3)$$

2.1.4 GELU

GELU 在 Transformer 和 BERT 等模型中被广泛应用，它结合了随机正则化的思想：

$$\text{GELU}(x) = x\Phi(x) = x \cdot \frac{1}{2} \left[1 + \text{erf}\left(\frac{x}{\sqrt{2}}\right) \right] \quad (4)$$

2.2 实验结果对比

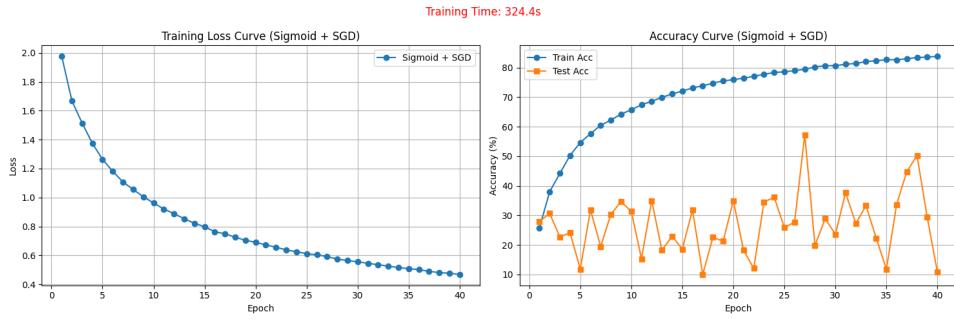


图 2: Sigmoid 激活函数下的训练曲线



图 3: LeakyReLU 激活函数下的训练曲线

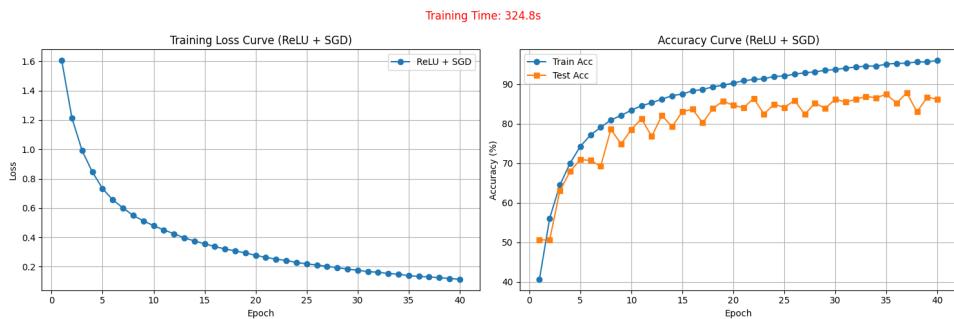


图 4: ReLU 激活函数下的训练曲线

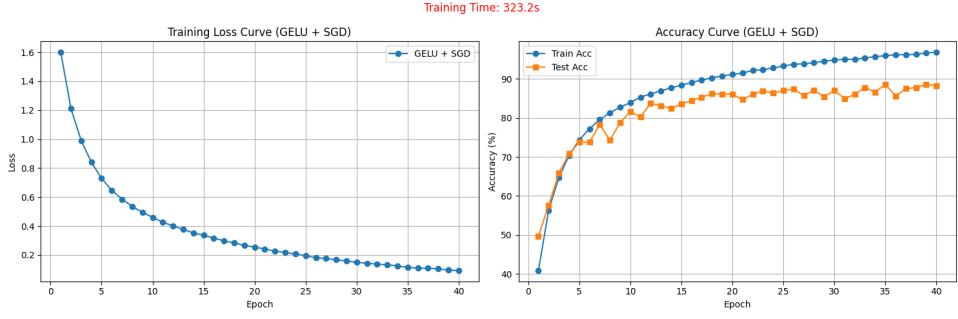


图 5: GELU 激活函数下的训练曲线

结果分析:

3 优化策略的对比与分析

优化器决定了网络参数更新的方式。实验在固定学习率 ($LR = 0.01$) 的条件下对比了以下三种优化器。

3.1 数学原理

3.1.1 SGD (随机梯度下降)

最基本的参数更新方法，每次迭代使用一个 Batch 的数据计算梯度：

$$w_{t+1} = w_t - \eta \nabla L(w_t) \quad (5)$$

其中 η 为学习率。

3.1.2 SGD with Momentum

为了抑制震荡并加速收敛，引入动量项 v_t (实验中 $\mu = 0.9$)：

$$v_{t+1} = \mu v_t + \nabla L(w_t) \quad (6)$$

$$w_{t+1} = w_t - \eta v_{t+1} \quad (7)$$

3.1.3 Adam (Adaptive Moment Estimation)

Adam 结合了动量法和 RMSProp，自适应地调整每个参数的学习率。它利用了一阶矩估计 m_t 和二阶矩估计 v_t :

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (8)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (9)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (10)$$

$$w_{t+1} = w_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (11)$$

3.2 实验结果对比



图 6:

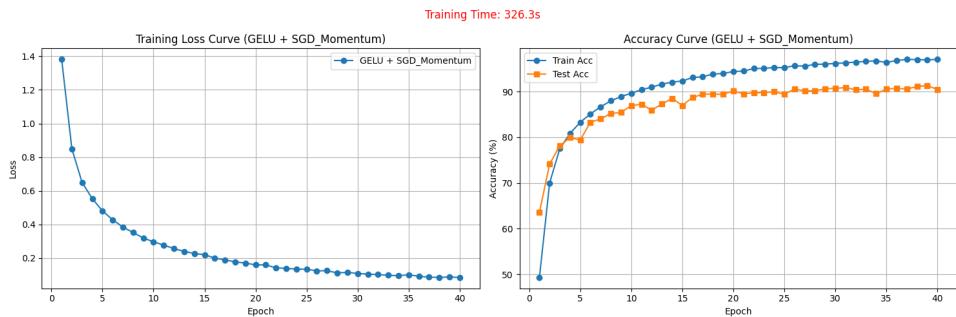


图 7:



图 8:



图 9: 不同优化器下的准确率变化曲线

结果分析:

4 模块设计创新：Ghost Module

4.1 改进动机

在传统的 CNN 中，特征图通常存在大量的冗余（相似的特征图）。*GhostNet : MoreFeaturesfromCheapOperations* 指出，这些冗余特征图可以通过廉价的线性变换从少量“本质特征图”生成，从而减少计算量和参数量。

4.2 改进原理

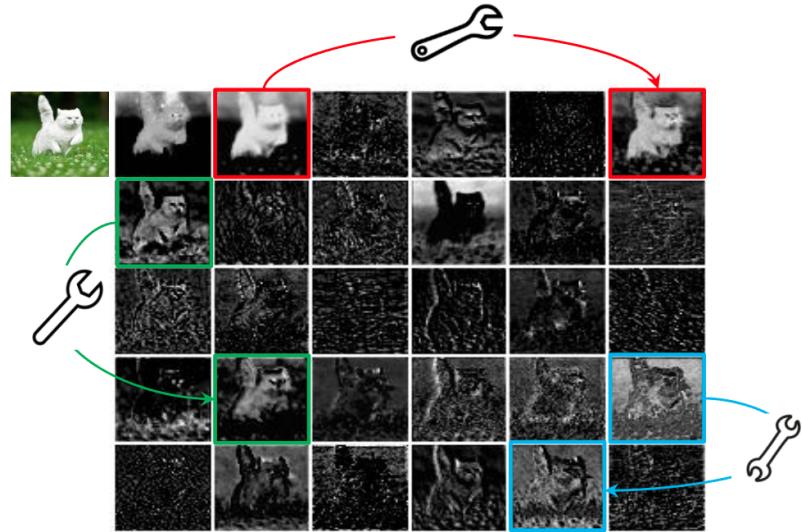


图 10: ResNet-50 特征图相似性示意图

如图, 论文作者观察到, 在训练好的深度神经网络(如 ResNet-50)中, 特征图之间存在惊人的相似性, 例如很多特征图都可以由一张图经过微小的变换生成。既然这些图高度相关, 那么我们就没有必要用独立的卷积核去学习它们, 而是可以通过廉价的线性变换生成这些冗余特征图, 从而节省计算资源。

Table 2. MSE error v.s. different kernel sizes.

MSE (10^{-3})	$d=1$	$d=3$	$d=5$	$d=7$
red pair	4.0	3.3	3.3	3.2
green pair	25.0	24.3	24.1	23.9
blue pair	12.1	11.2	11.1	11.0

图 11: 特征图拟合实验结果

作者做了一个简单的实验: 取 ResNet-50 中的一对相似特征图, 尝试用一个微小的深度卷积核去拟合它们之间的变换关系。结果发现, 重建误差(MSE) 极小。这证明了复杂的卷积操作生成的很多特征, 完全可以用极低成本的线性变换来替代, 而不会丢失太多信息。

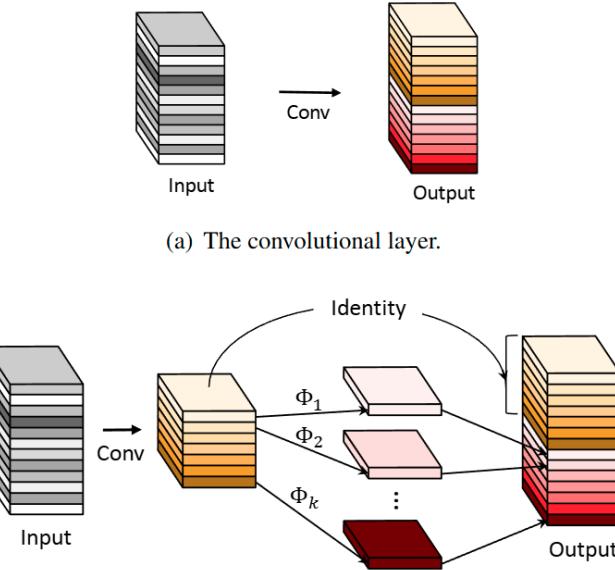


图 12: Ghost Module 原始结构示意图

如图是*GhostNet : MoreFeaturesfromCheapOperations*论文中的 Ghost Module 结构示意图。在 Ghost Module 中，首先通过普通卷积核，且核和通道的数量少于原始计划，生成“本质特征图”。然后通过廉价的线性操作(本实验采用卷积`nn.Conv2d`)生成冗余特征图。最后将两部分特征图拼接，得到最终输出。

4.3 代码实现

本实验基于*GhostNet : MoreFeaturesfromCheapOperations*，设计了 `GhostModule` 替代 ResNet 中的标准卷积层。核心代码如下：

```

1 class GhostModule(nn.Module):
2     def __init__(self, inp, oup, kernel_size=1, ratio=2, dw_size=3, stride=1,
3      ↪ relu=True):
4         super(GhostModule, self).__init__()
5         self.oup = oup
6         init_channels = math.ceil(oup / ratio)
7         new_channels = init_channels * (ratio - 1)
8         self.primary_conv = nn.Sequential(
9             nn.Conv2d(inp, init_channels, kernel_size, stride, kernel_size//2,
10            ↪ bias=False),
11             nn.BatchNorm2d(init_channels),
12             nn.ReLU(inplace=True) if relu else nn.Sequential(),
13         )
14         self.cheap_operation = nn.Sequential(

```

```

13     nn.Conv2d(init_channels, new_channels, dw_size, 1, dw_size//2,
14     ↪ groups=init_channels, bias=False),
15     nn.BatchNorm2d(new_channels),
16     nn.ReLU(inplace=True) if relu else nn.Sequential(),
17 )
18 def forward(self, x):
19     x1 = self.primary_conv(x)
20     x2 = self.cheap_operation(x1)
21     out = torch.cat([x1, x2], dim=1)
22     return out[:, :self.outp, :, :]

```

Listing 2: Ghost Module 核心实现代码

4.4 改进后的网络

我们将原 ResNet 中的 3×3 卷积替换为 GhostModule，设置 `ratio=2`，意味着理论上减少了一半的计算量。

4.5 性能评估

将改进后的 ResNet-Ghost 与原始 ResNet-18 进行对比：

表 1: ResNet-18 与 ResNet-Ghost 大小对比

Model	Parameters
ResNet-18	11.17M
ResNet-Ghost	5.7M

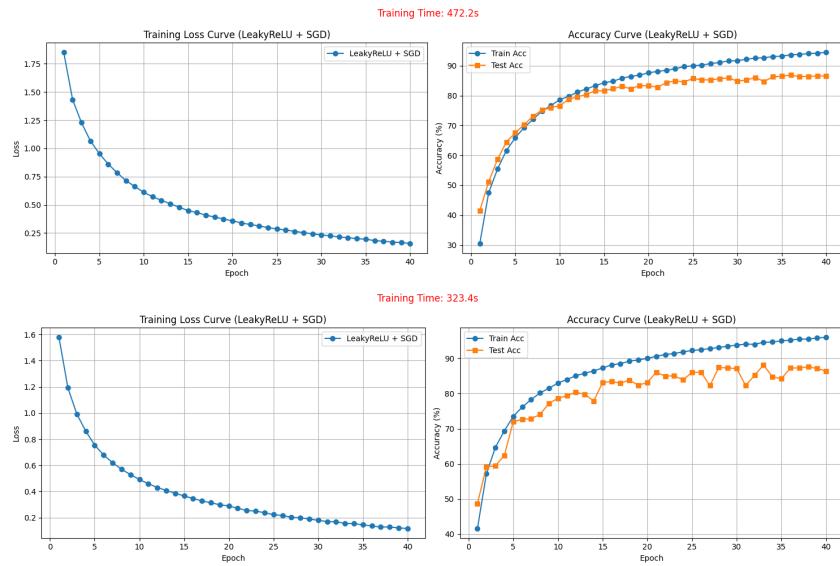


图 13: 训练过程对比1: 上为 ResNet-Ghost, 下为原 ResNet-18

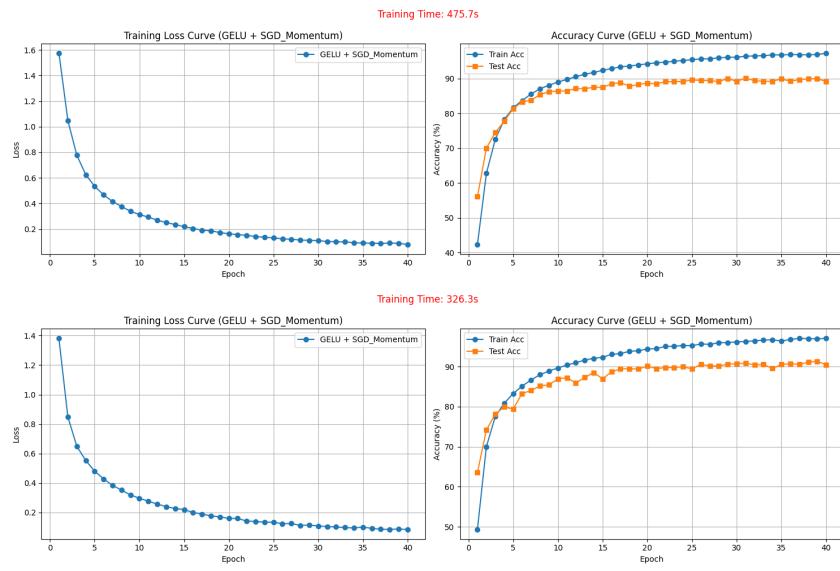


图 14: 训练过程对比2: 上为 ResNet-Ghost, 下为原 ResNet-18

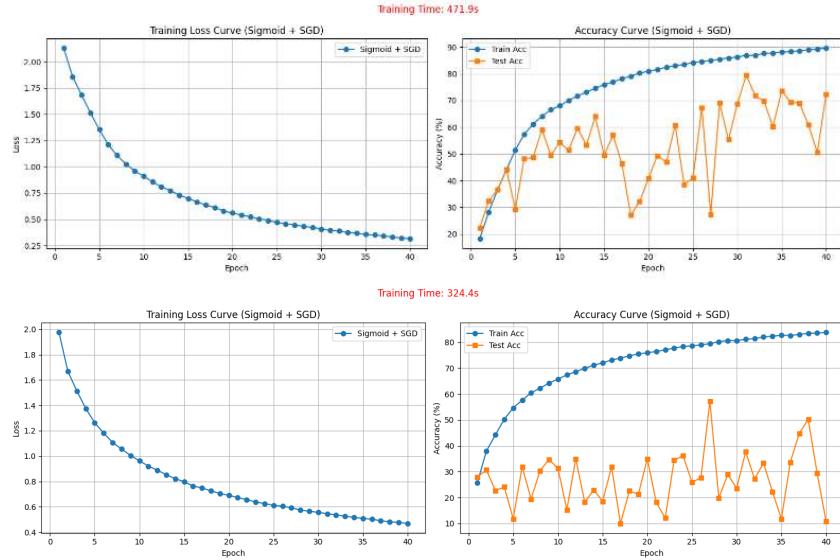


图 15: 训练过程对比3: 上为 ResNet-Ghost, 下为原 ResNet-18

分析

- Ghost 版本在参数量砍半的情况下，最终的测试集准确率几乎没有明显的损失，验证了特征图冗余性的假设。
- 虽然参数减少，但是由于Ghost Module 将一个大卷积拆成了两步：少量标准卷积 + Depthwise 卷积 + Concat。这增加了操作的碎片化程度。GPU 需要启动更多的 Kernel，频繁的 Kernel Launch 开销抵消了计算量的减少，这体现在训练时间不降反增上。
- 此外，还可以注意到，Ghost 版本的训练曲线更平滑，验证集准确率的波动更小，这可能是因为Ghost Module 自带的“结构正则化”效应，即Ghost Module 限制了模型的表达能力，减少了过拟合的可能性。

5 实验总结

本次实验通过复现 ResNet-18 并进行模块化改进，得出以下结论：

1. 激活函数方面，ReLU 及其变体（LeakyReLU）在深层网络中表现稳定，优于 Sigmoid。
2. 优化器方面，Adam 收敛速度最快，但在某些情况下 SGD+Momentum 能获得更好的最终泛化能力。
3. 通过引入 Ghost Module，模型在保持精度的同时，参数利用率得到了提升，验证了特征图冗余性假设的合理性。